

ESTATÍSTICA

Michelle Hanne Soares de Andrade

michellehanne.andrade@gmail.com



Inferência Bayesiana

Inferência Bayesiana

A teoria Bayesiana foi desenvolvida por Thomas Bayes em meados do século XVIII, o qual propôs uma **teoria subjetiva de probabilidade**, baseada principalmente em um conhecimento **a priori** em relação às incertezas envolvidas no estudo.

Inferência Bayesiana

A **inferência Bayesiana** é o processo de encontrar um **modelo de probabilidade** para um **conjunto de dados** e resumir o resultado por uma **distribuição de probabilidade** sobre os **parâmetros do modelo** e sobre **quantidades não observadas**, que poderão servir de **predição** para novas observações (GELMAN ET AL., 2003)

A metodologia Bayesiana

- Consiste de informações referentes aos dados amostrais (**função de verossimilhança***), de um conhecimento prévio a respeito dos **parâmetros (distribuição a priori)** e, a partir destas duas informações, do cálculo de uma **distribuição a posteriori dos parâmetros**, na qual todas as decisões e inferências são realizadas.

*O princípio de verossimilhança sustenta que toda informação dada pela amostra ou pela experiência está contida na função de verossimilhança.

Inferência Bayesiana - Aplicações

- Previsão de Investimento e Bolsa de Valores
- Fraude em cartões de crédito
- Detectar aviões num radar
- Classificação de texto (Análise de Sentimento)
- Detecção de Ataques em Redes de Computadores
- Detecção de *Spammers* em Redes Sociais
- Reconhecimento de padrão


Teorema de Bayes

Definição: Seja S um espaço amostral e A_1, A_2, \dots, A_k , k eventos. Diz-se que A_1, A_2, \dots, A_k formam uma partição de S se:

$$A_i \neq \emptyset, i = 1, 2, \dots, k$$

$$\bigcup_{i=1}^k A_i = S,$$

$$A_i \cap A_j = \emptyset, i \neq j$$



$A_1, A_2, A_3, A_4, A_5, \dots, A_k$ formam uma partição de S .

Teorema de Bayes

Seja B um evento qualquer de S, onde:

$$B = (B \cap A_1) \cup (B \cap A_2) \cup \dots \cup (B \cap A_k)$$

$$P(B) = \sum_{j=1}^k P(A_j) P\left(\frac{B}{A_j}\right), j = 1, 2, \dots, k \quad (*)$$

$$P(B \cap A_i) = P(A_i) \cdot P\left(\frac{B}{A_i}\right), \quad (**)$$

$$P\left(\frac{A_i}{B}\right) = \frac{P(B \cap A_i)}{P(B)}, \quad (***)$$

Teorema de Bayes

substituindo as equações (*) e (**) na equação (***) temos:

$$P\left(\frac{A_i}{B}\right) = \frac{P(A_i).P\left(\frac{B}{A_i}\right)}{\sum_{j=1}^k P(A_j).P\left(\frac{B}{A_j}\right)}, j = 1, 2, \dots, k.$$

Teorema de Bayes


$$P(A_i | B) = \frac{P(A_i) P(B | A_i)}{\sum P(A_i) P(B | A_i)}$$

Teorema de Bayes – Exemplo 1

- Chamando B o evento “fabricado em B” e d o evento “HD defeituoso”, podemos escrever:
- Uma peça defeituosa pode provir de qualquer uma das 3 fábricas (e só de uma!). Logo, eventos mutuamente excludentes.
- Portanto:

$$P(d) = P(A)P(d|A) + P(B)P(d|B) + P(C)P(d|C)$$

$$P(B|d) = \frac{P(B \cap d)}{P(d)} = \frac{P(B) P(d|B)}{P(d)}$$



Teorema de Bayes – Exemplo 1

- Assim, de acordo com os valores fornecidos, temos que:

$$P(d) = (0,40 \times 0,02) + (0,35 \times 0,01) + (0,25 \times 0,03) = 0,019$$

- E, portanto,

$$P(B|d) = \frac{(0,35 \times 0,01)}{(0,40 \times 0,02) + (0,35 \times 0,01) + (0,25 \times 0,03)} = 0,184 = 18,4\%$$

Teorema de Bayes – Exemplo – Método Alternativo

- Construa uma Tabela de Probabilidades

	A	B	C	Totais
Bom	0,392	0,3465	0,2425	0,981
Defeito	0,008	0,0035	0,0075	0,019
Totais	0,40	0,35	0,25	1

$$P(B|\text{defeito})=0,0035/0,019=0,184$$

Teorema de Bayes – Exemplo 2

- Recomenda-se que, a partir dos **40 anos**, as **mulheres façam mamografias anuais**. Nessa idade, **1% (0,01)** das mulheres são **portadoras de um tumor assintomático de mama**, ou seja, **99% (0,99) não tem câncer**. Sabe-se que a mamografia apresenta resultado positivo em **80% das mulheres com câncer de mama**, mas esse mesmo resultado ocorre também com **9,6% das mulheres sem o câncer**, isto é, a mulher pode ter o resultado positivo mesmo sem ter propriamente câncer (falso positivo).

Teorema de Bayes – Exemplo 2

- *Imagine agora que você chega em casa e encontra sua tia aos prantos, desesperada, **porque fez uma mamografia de rotina e o resultado foi positivo!** Qual a probabilidade de ela ter um câncer de mama?*

Teorema de Bayes – Exemplo 2

Resolução: Em primeiro lugar, **sua tia tem o câncer de mama (CA)** ou não (**não-CA**). Essas alternativas, mutuamente excludentes (concorda?), podem ser colocadas em uma tabela, como abaixo:

	TEM CÂNCER	NÃO TEM CÂNCER
Probabilidade a priori	0,01	0,99

Esta é chamada **probabilidade a priori – ter câncer ou não ter**. Como em média **1% das mulheres** de 40 anos têm um tumor de mama, a **probabilidade a priori de sua tia ter um câncer é de 1% (0,01)** e de não ter é de 99% (0,99).

Teorema de Bayes – Exemplo 2

Agora vamos incorporar o resultado da mamografia.

- Se o câncer de mama está presente, a probabilidade condicional de a mamografia **ser positiva é 0,80 (80%)**, e se não está presente **é de 0,096 (9,6%) (concorda?)**.
- Multiplicando a **probabilidade a priori pela chance de a mulher ter um câncer de mama, sob condicional**, obtemos a **probabilidade conjunta**: esse ponto de vista, um teste médico funciona como um ‘modificador de opinião’, **atualizando uma hipótese inicial (probabilidade a priori) para gerar outra (probabilidade a posteriori)**.

Teorema de Bayes – Exemplo 2

	TEM CÂNCER	NÃO TEM CÂNCER
Probabilidade a priori	0,01	0,99
Probabilidade condicional	0,8	0,096
Probabilidade Conjunta	$0,01 \times 0,8 = 0,008$	$0,99 \times 0,096 = 0,0095$

- Observe que a soma das **probabilidades a priori** é 1, mas isso não acontece com as **probabilidades conjuntas**.
- Para fazer com que essa segunda **soma se torne 1**, é preciso usar uma **normalização**. Para isto dividimos cada uma das probabilidades conjuntas pela **soma das duas (0,0175)**. Chegamos assim à **chamada probabilidade a posteriori**.

Teorema de Bayes – Exemplo 2

	TEM CÂNCER	NÃO TEM CÂNCER
Probabilidade a priori	0,01	0,99
Probabilidade condicional	0,8	0,096
Probabilidade Conjunta	$0,01 \times 0,8 = 0,008$	$0,99 \times 0,096 = 0,0095$

- Observe que a soma das **probabilidades a priori** é 1, mas isso não acontece com as **probabilidades conjuntas**.
- Para fazer com que essa segunda **soma se torne 1**, é preciso usar uma **normalização**. Para isto dividimos cada uma das probabilidades conjuntas pela **soma das duas (0,0175)**. Chegamos assim à **chamada probabilidade a posteriori**.

Teorema de Bayes – Exemplo 2

	TEM CÂNCER	NÃO TEM CÂNCER
Probabilidade a priori	0,01	0,99
Probabilidade condicional	0,8	0,096
Probabilidade Conjunta	$0,01 \times 0,8 = 0,008$	$0,99 \times 0,096 = 0,0095$
Normalização	$(0,008 + 0,0095 = 0,0175)$	
Probabilidade a posteriori	$0,008/0,0175 = 0,46$	$0,0095/0,0175 = 0,54$

Teorema de Bayes – Exemplo 2

- Portanto, o raciocínio Bayesiano nos levou, de modo muito simples, a concluir que a probabilidade a posteriori (ou seja, após o teste) de sua tia não ter um câncer de mama é de 0,54 (54%) e você pode tranquilizá-la de que a situação não é inevitável.



Probabilidade da interseção de dois eventos

Probabilidade da Interseção de dois Eventos

A probabilidade da interseção de dois eventos ou probabilidade de **eventos sucessivos** determina a chance, a possibilidade, de dois eventos ocorrerem simultânea ou sucessivamente.

Probabilidade da Interseção de dois Eventos

- Sejam A e B dois eventos de um espaço amostral S. A probabilidade de $A \cap B$ é dada por:

$$p(A \cap B) = p(B|A) \cdot p(A) = p(B) \cdot p(A|B)$$

Onde:

$p(A \cap B)$ → é a probabilidade da ocorrência simultânea de A e B

$p(A)$ → é a probabilidade de ocorrer o evento A

$p(B|A)$ → é a probabilidade de ocorrer o evento B sabendo da ocorrência de A (probabilidade condicional)

Eventos Independentes

Se os eventos **A** e **B** forem independentes (ou seja, se a ocorrência de um não interferir na probabilidade de ocorrer outro), a fórmula para o cálculo da probabilidade da intersecção será dada por:

$$p(A \cap B) = p(A) \cdot p(B)$$

Quando o fato de ter ocorrido o evento B não alterar a probabilidade de ocorrer o evento A, ou seja, quando A e B forem eventos independentes.

Eventos Independentes - Exemplo

- Uma moeda e um dado são lançados simultaneamente. Qual a probabilidade de ocorrer coroa e número primo?

Solução: Primeiro, vamos determinar o espaço amostral S , que é o conjunto com todos os possíveis resultados. Para melhor compreensão, iremos denominar cara de C e coroa de K. Assim,

$$S = \{(C, 1); (C, 2); (C, 3); (C, 4); (C, 5); (C, 6); (K, 1); (K, 2); (K, 3); (K, 4); (K, 5); (K, 6)\} \text{ logo } n(S) = 12$$

Eventos Independentes - Exemplo

Vamos descrever os eventos A e B.

A: ocorrer coroa

B: ocorrer número primo

É fácil ver que esses dois eventos são independentes, um pode ocorrer sem a interferência do outro. Dessa forma, para resolução, utilizaremos a fórmula:

$$P(A \cap B) = p(A) \cdot p(B)$$

$p(A) = \frac{1}{2}$, pois no lançamento de uma moeda há metade de chance de sair cara e metade de sair coroa.

$p(B) = \frac{3}{6} = \frac{1}{2}$, pois dos 6 possíveis resultados no lançamento de um dado, três deles são números primos.

Logo, $P(A \cap B) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$

Interseção de dois Eventos- Exemplo

- Uma urna contém 10 etiquetas identificadas pelas letras A, B, C, D, ..., I, J. Duas delas são retiradas ao acaso, sucessivamente. Qual a probabilidade de saírem duas vogais, se a extração é feita sem reposição?

Solução: Vamos determinar os dois eventos envolvidos.

Evento A: sair uma vogal

Evento B: sair uma vogal

Interseção de dois Eventos- Exemplo

O fato de não haver reposição das etiquetas indica que não haverá a mesma quantidade de etiquetas após a ocorrência de um deles. Dessa forma, utilizaremos a expressão:

$$P(A \cap B) = p(A | B) \cdot p(B)$$

Vamos então calcular $p(B)$ e $p(A | B)$.

$p(B) = 3/10$, pois, das dez letras, apenas 3 são vogais.

$p(A | B) = 2/9$, pois, se B ocorreu, restaram 9 letras e, dessas, apenas 2 são vogais.

Logo,

$$P(A \cap B) = 2/9 \cdot 3/10 = 6/90 = 1/15$$

Teorema da Probabilidade Condicional

A probabilidade condicional também é uma probabilidade ($P(.|B)$, para B um subconjunto fixo de Ω), ou seja a probabilidade condicional satisfaz os três axiomas de probabilidade.

$$\mathbb{P}(\Omega|B) = \frac{\mathbb{P}(\Omega \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B)}{\mathbb{P}(B)} = 1$$

E que diz:

$$\mathbb{P}(\emptyset|B) = \frac{\mathbb{P}(\emptyset \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(\emptyset)}{\mathbb{P}(B)} = \frac{0}{\mathbb{P}(B)} = 0$$

E que demonstra o Primeiro Axioma.

Teorema da Probabilidade Condicional

O segundo axioma diz que $0 \leq \mathbb{P}(A|B) \leq 1$, para qualquer $A \subset \Omega$. Observe que $\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$, e como $A \cap B \subset B$. Temos que por P4 que $0 \leq \mathbb{P}(A \cap B) \leq \mathbb{P}(B)$, o que implica que $0 \leq \mathbb{P}(A|B) \leq 1$.

P4. Se $A \subset B$, então $\mathbb{P}(A) \leq \mathbb{P}(B)$.

De fato, temos que se $A \subset B$ então $B = A \cup (B - A)$, sendo que esta união é disjunta.

Teorema da Probabilidade Condicional

- O terceiro e último axioma diz que para qualquer sequência de eventos mutuamente exclusivos A_1, A_2, \dots , temos que

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n | B\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n | B).$$

- Logo, a probabilidade condicional satisfaz todos os axiomas da probabilidade, o que implica que a probabilidade condicional também é uma probabilidade.

Árvore de Probabilidades Condicionais

- Suponha que uma pessoa está participando de um programa de televisão e lhe é fornecida a possibilidade de escolher entre portas. Atrás de uma das portas existe um carro e atrás das demais não existe prêmio algum. O participante escolhe uma porta, digamos a porta a e o apresentador abre outra porta, digamos a porta b , revelando que não há nada atrás dela e então oferece ao participante a oportunidade de trocar de porta. **O que é mais vantajoso, trocar ou não a porta escolhida?**

Árvore de Probabilidades Condicionais

- Este é um problema clássico, conhecido como paradoxo de Monty Hall.
- A resposta intuitiva é não mudar de porta. O apresentador teria nos ajudado, já que nossas chances subiram de $1/3$ para $1/2$, mas realmente não faria diferença trocar ou não de porta uma vez que ambas teriam as mesmas chances de possuírem o prêmio. No entanto, esta resposta está errada, pois a porta que o apresentador abre depende da porta que o concorrente escolher inicialmente.
- Na verdade, é mais vantajoso trocar de porta e, ao fazê-lo a chance do participante ganhar o carro é de $2/3$.

Árvore de Probabilidades Condicionais

Solução 1: Podemos resolver utilizando a Descrição do Problema

Estratégia 1, onde o participante seleciona uma porta e, se lhe é fornecida a oportunidade de **trocar de porta, ele recusa**.

Estratégia 2, na qual o participante **sempre troca a porta** escolhida.

- Utilizando a estratégia 1, o participante ganhará o carro com **probabilidade $1/3$** , já que em $1/3$ das vezes a porta que ele escolhe terá o carro com o prêmio.

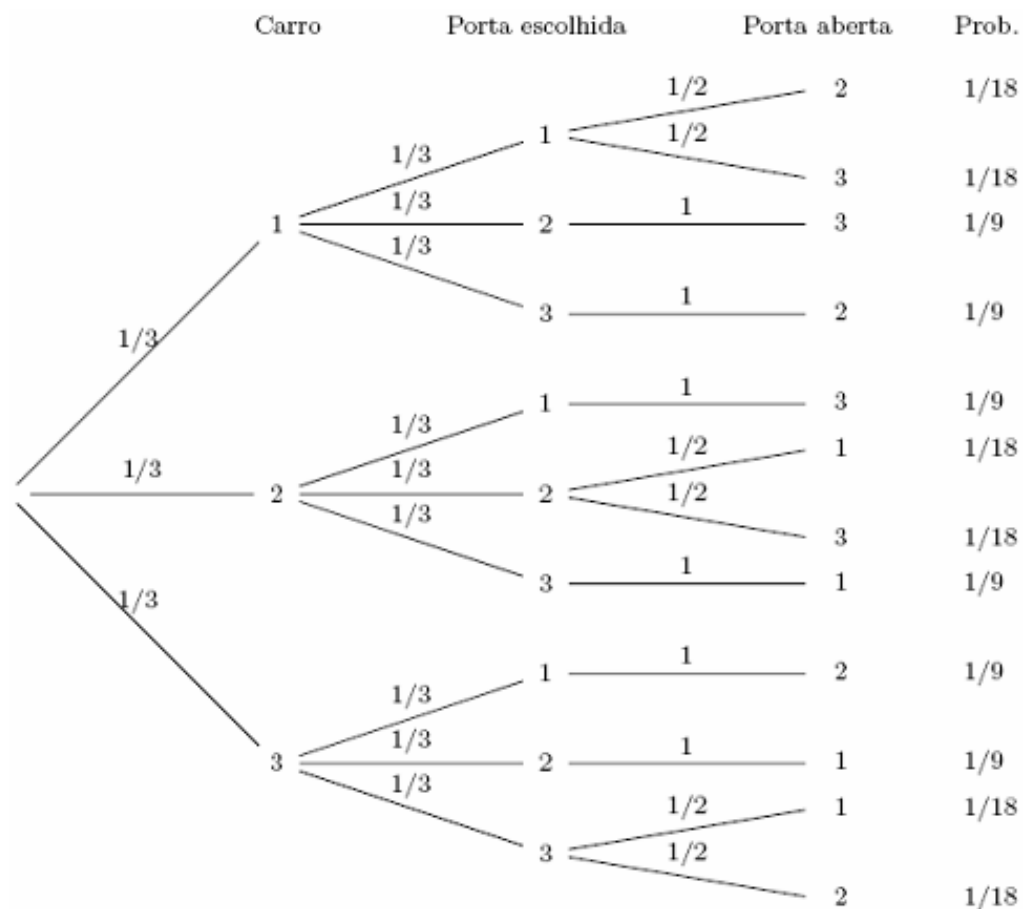
Árvore de Probabilidades Condicionais

- Utilizando a estratégia 2, o participante somente ganhará o carro se, a princípio escolhe uma porta que não contém o carro como prêmio, o que ocorre em $2/3$ das vezes, ou seja, a probabilidade de ganhar com a **estratégia 2 é de $2/3$ e, portanto, duas vezes maior do que utilizando a estratégia 1.**

Árvore de Probabilidades Condicionais

- **Solução 2:** Podemos resolver este problema utilizando os conceitos de **probabilidade condicional**.
- Podemos analisar o problema através de um diagrama de árvore. Assumimos que se o apresentador pode escolher entre as portas (ou seja, o participante escolheu a porta com o carro), então ele escolhe cada porta com probabilidade $1/2$. Temos a Árvore Resultante.

Árvore de Probabilidades Condicionais



Exemplo 4 – Teorema Bayesiano

- Suponha que a ocorrência de chuva (ou não) dependa de das condições do tempo no dia imediatamente anterior. **Admitamos que se chova hoje, choverá amanhã com probabilidade de 0,7** e que **se não chove hoje, então choverá amanhã com probabilidade de 0,4**. Sabendo que choveu hoje, calcule a probabilidade de chover depois de amanhã.

Exemplo 4 – Teorema Bayesiano

- Solução:

Consideremos nosso espaço amostral $\Omega = \{(\omega_1, \omega_2, \omega_3) : \omega_i \in \{\text{chover, não chover}\}\}$. Seja o evento $A_1 = \{\text{chover hoje(0)}, A_2 = \{\text{chover amanhã}\}$ e $A_3 = \{\text{chover depois de amanhã}\}$. Queremos encontrar $\mathbb{P}(A_3|A_1)$, mas

$$\begin{aligned}\mathbb{P}(A_3|A_1) &= \mathbb{P}(\Omega \cap A_3|A_1) \\ &= \mathbb{P}(A_3 \cap (A_2 \cup A_2^c)|A_1) \\ &= \mathbb{P}(A_3 \cap A_2|A_1) + \mathbb{P}(A_3 \cap A_2^c|A_1)\end{aligned}$$

Exemplo 4 – Teorema Bayesiano

■ Solução:

$$\begin{aligned} &= \frac{\mathbb{P}(A_1 \cap A_2 \cup A_3)}{\mathbb{P}(A_1)} + \frac{\mathbb{P}(A_1 \cap A_2^C \cup A_3)}{\mathbb{P}(A_1)} \\ &= \frac{\mathbb{P}(A_3|A_1 \cap A_2) \cdot \mathbb{P}(A_2|A_1) \cdot \mathbb{P}(A_1)}{\mathbb{P}(A_1)} + \frac{\mathbb{P}(A_3|A_1 \cap A_2^C) \cdot \mathbb{P}(A_2^C|A_1) \cdot \mathbb{P}(A_1)}{\mathbb{P}(A_1)} \\ &= \mathbb{P}(A_3|A_1 \cap A_2) \cdot \mathbb{P}(A_2|A_1) + \mathbb{P}(A_3|A_1 \cap A_2^C) \cdot \mathbb{P}(A_2^C|A_1) \\ &= \mathbb{P}(A_3|A_2) \cdot \mathbb{P}(A_2|A_1) + \mathbb{P}(A_3|A_2^C) \cdot \mathbb{P}(A_2^C|A_1) \\ &= 0,7 \cdot 0,7 + 0,4 \cdot 0,3 \\ &= 0,61 \end{aligned}$$

Ou seja, sabendo que choveu hoje, a probabilidade de chover depois de amanhã é de 61%.